Construye | Proyecto MiBici

Etapa 1: propuesta y base reproducible

Equipo 49 · TC5061

Integrante	Matrícula	Usuario de Github
Daniel Ruán Aguilar	A01731921	DaniRuan
Saúl Salgado Ortega	A01423738	Drezneck-RM
Diego Sánchez Hernández	A01783237	dieguini95

Dato	Valor
Repositorio	https://github.com/dieguini95/TC5061-Proyecto-Equipo49
Versión del documento	1 (Etapa 1), 18 de octubre de 2026
Fecha límite de entrega	Domingo 18 de octubre de 2026, 23:59

Resumen

Proponemos tres preguntas de aprendizaje automático sobre los viajes de MiBici, el sistema de bicicletas públicas del Área Metropolitana de Guadalajara:
P1 estima la demanda de salidas por estación-hora (regresión),
P2 clasifica el riesgo de que una estación quede vacía o llena en las siguientes dos horas (clasificación binaria)
P3 agrupa estaciones por su patrón de uso (clustering).

Usamos 12 meses de datos abiertos (octubre de 2025 a septiembre de 2026, 4,497,877 viajes antes de limpieza) con una partición cronológica: entrenamiento de octubre de 2025 a junio de 2026, validación en julio y agosto, y prueba en septiembre de 2026.

1. Formulación del problema

El ML Canvas (plantilla v1.2 de Louis Dorard, licencia CC BY-SA 4.0; Dorard, 2018) está en la página siguiente y como archivo editable en el repositorio (references/ML_Canvas_MiBici_Equipo49.docx y .pdf).

MACHINE LEARNING CANVAS

Date: 16/10/2026 Iteration: 1 (Etapa 1). Designed for: MiBici (operador, rebalanceo y planeacion urbana) Designed by: Equipo 49 (TC5061)

PREDICTION TASK

What is the type of task?
Which entity are predictions made on?
What are the possible outcomes to predict?
When are outcomes observed?

P1 Regresion: viajes que salen de cada estacion por hora (conteo).

P2 Clasificacion: riesgo 0/1 de estacion vacia o llena en 2 h.

P3 Clustering: grupos de estaciones por patron de uso (k de 3 a 8).

Entidad: 469 estaciones.

Se observa: P1 y P2 cada hora; P3 con entrenamiento.

DECISIONS

How are predictions turned into actionable recommendations or decisions for the end-user? (Mention parameters of the process / application for this.)

P1: pronostico diario a las 00:00 para 24 h; reparte bicicletas antes del pico de 08:00.

P2: lista de estaciones en riesgo; se visitan las k mas criticas por hora (k por confirmar).

P3: guia donde expandir y que tipo de anclajes poner.

Umbral de P2 elegido en validacion (precision de al menos 0.5).

VALUE PROPOSITION

Who is the end beneficiary, and what specific pain points are addressed?
How will the ML solution integrate with their workflow, and through which user interfaces?

Beneficiarios: operador de MiBici y planeacion urbana.

Dolores: estaciones vacias o llenas en hora pico; reservas mal ubicadas.

Integracion: reporte diario en tabla y mapa.

DATA COLLECTION

How is the initial set of entities and outcomes sourced (e.g., database extracts, API pulls, manual labeling)?
What strategies are in place to update data continuously while controlling cost and maintaining freshness?

12 meses de CSV del portal (oct-2025 a sep-2026): 4,497,877 viajes antes de limpieza.

Ingesta reproducible (dataset.py) con manifiesto SHA-256 por archivo.

Frescura: un mes nuevo al mes. Sin costo; archivos de 27 a 42 MB.

Etiquetas derivadas de los viajes; sin etiquetado manual.

DATA SOURCES

Where can we get data on entities and observed outcomes? (Mention internal and external database tables or API methods.)

Viajes: mibici.net/es/datos-abiertos (CSV mensual): inicio, fin, origen, destino, usuario, genero, año de nacimiento.

Estaciones: nomenclatura (id, nombre, lat, lon, capacidad).

Sin inventario por estacion ni rebalanceo: limita P2.

Externos previstos: festivos de Mexico.

IMPACT SIMULATION

What are the cost/gain values for (in)correct decisions?
Which data is used to simulate pre-deployment impact?
What are the criteria for deployment?
Are there fairness constraints?

Costo y beneficio: sin datos financieros; confirmar con el operador costo de visita frente a viaje perdido.

Simulacion: validacion (jul-ago 2026) y prueba (sep 2026, 490,056 viajes).

Criterio: P2 supera la persistencia en PR-AUC; P1 supera el estacional-ingenuo en WAPE.

MAKING PREDICTIONS

Are predictions made in batch or in real time?
How frequently?
How much time is available for this (including featurization and decisions)?
Which computational resources are used?

Por lotes. P1: una vez al dia. P2: cada hora. P3: mensual o trimestral.

Tiempo: menos de 10 min por corrida (unas 470 estaciones).

Recursos: CPU de equipo personal o servidor pequeño. Sin GPU.

SUPUESTOS Y LIMITACIONES

P2: el riesgo es una aproximacion con viajes; 9% de estacion-dia no factibles (excluidas).

P1: conteos sobredispersos (varianza 5 veces la media; 62% de celdas en cero).

Los viajes observados son cota inferior de la demanda real (demanda no atendida).

Datos personales fuera de variables, MLflow y Git.

Licencia de datos: confirmar con la AMIM antes de publicar.

BUILDING MODELS

How many models are needed in production?
When should they be updated?
How much time is available for this (including featurization and analysis)?
Which computation resources are used?

Tres modelos en produccion, uno por pregunta.

Reentreno mensual con ventana movil de 12 meses; P3 trimestral o al cambiar la red.

Tiempo: pocos minutos por corrida con scikit-learn (CPU).

Registro y comparacion con MLflow Tracking.

FEATURES

What representations are used for entities at prediction time?
What aggregations or transformations are applied to raw data sources?

Calendario: hora, dia, mes, festivo y fin de semana.

Rezagos de 24, 48 y 168 h; media de 4 semanas (mismo dia y hora).

Capacidad y cluster de P3 (solo con entrenamiento).

P2: flujo neto hasta t; llegadas y salidas de 1 y 2 h.

Sin fuga: solo informacion previa a la prediccion.

MONITORING

Which metrics and KPIs are used to track the ML solution's impact once deployed, both for end-users and for the business?
How often should they be reviewed?

Negocio: viajes perdidos por estacion vacia o llena; visitas en riesgo. Alerta: si una metrica empeora 10% frente a la version anterior.

Modelo: WAPE y MAE (P1); PR-AUC (P2); silueta (P3).

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

ML Canvas del proyecto (Equipo 49). Designed for: MiBici (operador, rebalanceo y planeación urbana).

1.1 Las tres preguntas

Elemento	P1. Demanda (regresión)	P2. Riesgo de estación (clasificación)	P3. Perfiles (clustering)
Qué se predice o agrupa	$y(s, t)$: viajes que inician en la estación s durante la hora t.	$r(s, t) = 1$ si la estación s entra en riesgo (vacía o llena) en alguna de las siguientes $H = 2$ horas.	Grupos de estaciones que comparten patrón de uso.
Granularidad y horizonte	Estación-hora. Pronóstico emitido a las 00:00 del día D para las 24 horas de D (horizonte de 0 a 23 h).	Estación-hora, evaluada cada hora, con horizonte de 2 h.	Estación, con el perfil del periodo de entrenamiento.
Por qué es relevante	El operador necesita saber cuántas bicicletas se usarán en cada estación para mover flota antes del pico de la mañana y dejar reserva.	Una estación vacía pierde viajes y una llena no recibe bicicletas. Anticipar el problema permite rebalancear antes.	Tipificar estaciones (por ejemplo, residenciales, de trabajo o de ocio) para decidir dónde ampliar capacidad o instalar nuevas estaciones.
Quién lo usa y qué decide	Operador del sistema: cuántas bicicletas mover a cada estación y cuántas reservar.	Equipo de rebalanceo: qué estaciones visitar en la siguiente ronda, con un presupuesto de visitas por hora.	Planeación urbana: dónde instalar estaciones o ampliar anclajes.
Aproximación clave	Solo rezagos de 24 h o más, para que ninguna variable use el día en curso.	MiBici no publica inventario por estación. Se estima con el flujo neto acumulado $F(t)$ de los viajes (ver 1.2).	Perfil horario normalizado de salidas y llegadas, desbalance, volumen, duración mediana y capacidad.

1.2 Aproximación del riesgo en P2

Como no hay inventario observado, estimamos el riesgo solo con viajes:

- Flujo neto acumulado por estación-día: $F(t)$ = llegadas menos salidas desde las 00:00.
- Rango de inventario inicial factible: $L = \max(0, -\min F)$ y $U = \min(C, C - \max F)$, donde C es la capacidad. Solo es válido si $L <= U$.
- Inventario estimado $I(t) = s0 + F(t)$, con $s0 = (L + U) / 2$. Se usa **solo para construir la etiqueta**, que puede mirar al futuro porque es la respuesta que queremos predecir. Las variables de entrada no pueden hacerlo.
- Un día infactible no permite estimar s0. Con solo viajes, el 9.07% de las estación-día con actividad (142,406 en 12 meses) son infactibles; sobre la malla completa de estación por día (175,680 filas) son el 7.35%. P2 excluye las infactibles del entrenamiento y de la evaluación, y lo reporta. Como los viajes observados son una cota inferior de la demanda (Liu y Pelechrinis, 2021; O'Mahony y Shmoys, 2015), la etiqueta es una aproximación.

Limitación: el rebalanceo operativo y las bicicletas no registradas como viaje no están en los datos. La etiqueta es una aproximación del riesgo, no una medición del inventario real. Se valida en el plan de experimentos (sección 4).

2. Datos

2.1 Fuente, tamaño y justificación del rango

- **Viajes (MiBici, s.f.): https://mibici.net/es/datos-abiertos/ (12 CSV mensuales). Los enlaces cambian de ID, por eso la ingesta los lee de la página.**https://mibici.net/es/datos-abiertos/
- **Estaciones:** https://mibici.net/site/assets/files/1118/nomenclatura_2026_09.csv (484 estaciones en el catálogo de septiembre de 2026).

Mes	Viajes	Codificación	Mes	Viajes	Codificación
2025-10	420,064	UTF-8	2026-06	355,303	UTF-8
2025-11	380,328	UTF-8	2026-07	388,257	UTF-8
2025-12	335,420	UTF-8	2026-08	393,524	UTF-8
2026-01	357,180	cp1252	2026-09	490,056	UTF-8
2026-02	333,756	UTF-8			
2026-03	376,243	UTF-8	**Total**	**4,497,877**	
2026-04	351,851	UTF-8			
2026-05	315,895	UTF-8			

Los 12 archivos coinciden en tamaño con el Content-Length del servidor. Después de eliminar 758 duplicados exactos (todos en septiembre de 2026) quedan 4,497,119 viajes. Hay 365 días con viajes, con mediana de 13,027 viajes por día (mínimo 2,275 el 22 de febrero de 2026; máximo 21,677 el 30 de septiembre de 2026).

Estaciones: 469 de las 484 estaciones del catálogo tienen al menos una salida en 12 meses y 15 no tienen ningún viaje. Dos IDs fuera de catálogo también tienen salidas, por lo que hay 471 IDs de origen en total (esta es la cifra de "activas" que aparece en el EDA y en el notebook). Hay tres IDs en los viajes que no están en el catálogo y se conservan marcados. La capacidad tiene mediana 15 anclajes (rango de 0 a 39); cuatro estaciones tienen capacidad 0 y ningún viaje.

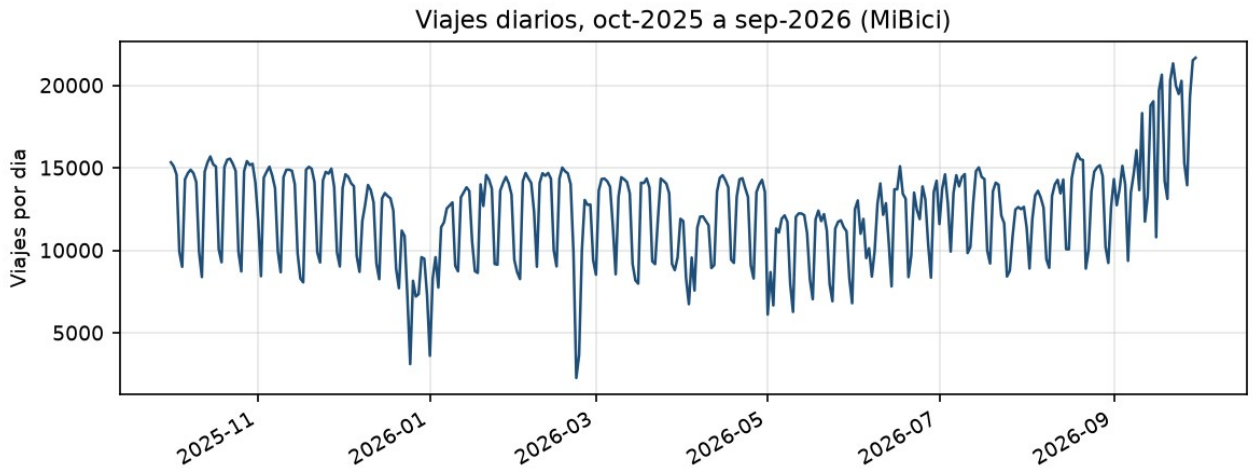


Figura 1. Viajes por día, octubre de 2025 a septiembre de 2026 (fuente: EDA del repositorio).

Decisión de rango de fechas

Alternativa	Razón para elegir o descartar
(a) Solo septiembre de 2026 (490,056 viajes, 468 estaciones activas)	Descartada. Sin estacionalidad ni varias semanas de prueba; el conjunto de prueba quedaría con pocos días de observaciones distintas.
(b) Seis meses, de abril a septiembre de 2026	Descartada. No cubre un ciclo anual completo: deja fuera octubre a marzo y sus patrones de temporada.
(c) Doce meses, de octubre de 2025 a septiembre de 2026 (elegida)	Nueve meses de entrenamiento, dos de validación y uno de prueba. Cubre un ciclo estacional completo. Toda la configuración está en config.py, así que el rango es ajustable.

Unidad de tiempo: hora. Los viajes duran alrededor de 9 minutos y los picos están a las 08:00 y 18:00. Un día es demasiado grueso para P2. El horario de servicio exacto no está publicado en los datos; se confirmará con MiBici porque cambia qué horas se consideran.

2.2 Variables originales y construcción de objetivos

Variable original	Uso
Inicio_del_viaje	Hora de salida (P1 y P3). Base del objetivo de P1 y del flujo de P2.
Fin_del_viaje	Hora de llegada (P2). Base de las llegadas.
Origen_Id, Destino_Id	Estación de salida y de llegada.
dpcapacity (nomenclatura)	Capacidad C en P2 y variable en P1 y P3.
latitude, longitude	Mapa de P3 y baseline geográfico. No es variable de P1.
Viaje_Id	Solo para detectar duplicados.
Usuario_Id, Genero, Año_de_nacimiento	**No se usan como variables ni se publican** (ver 2.4).

- **P1:** $y(s, t)$ = número de viajes con Origen_Id = s e Inicio_del_viaje en la hora t.
- **P2:** $F(s, t)$ = suma acumulada de (llegadas menos salidas) por hora desde las 00:00 del día. La etiqueta se describe en 1.2.
- **P3:** perfil horario normalizado de salidas y llegadas, desbalance (llegadas - salidas) / (llegadas + salidas), volumen, duración mediana de los viajes de salida y capacidad.

2.3 Limpieza

Problema	12 meses	%	Tratamiento
Duplicados exactos	758	0.02	Eliminar
Duración menor o igual a 0 min	3,791	0.08	Eliminar (registro inválido)
Duración menor a 1 min	157,690	3.51	Conservar y marcar (posibles inicios fallidos)
Origen igual a destino	295,263	6.56	Conservar (viaje redondo es válido) y marcar
Duración mayor a 180 min	510	0.01	Conservar y marcar
Género nulo o vacío	32,982	0.73	Valor NA explícito; no es variable de entrada
Año de nacimiento vacío, nulo o menor a 1930	853	0.02	No se usa como variable
Estación fuera de catálogo	3 IDs	-	Conservar el viaje y marcar la estación sin coordenadas
Encoding cp1252 (2026-01)	1 mes	-	Leer con su codificación y validar contra el esquema

Chequeo de factibilidad de P2. La regla $\max F - \min F <= C$ indica en qué estación-día el inventario puede reconstruirse solo con viajes. En 12 meses, 90.93% de las estación-día activas son factibles (142,406 en total). En septiembre de 2026, que es el conjunto de prueba, son factibles 92.33%. Por capacidad, los rangos 11 a 20 y 21 a 30 anclajes tienen cerca de 9% no factibles, y el rango 31 a 39 tiene 17.65%. Los días no factibles se excluyen y se reportan.

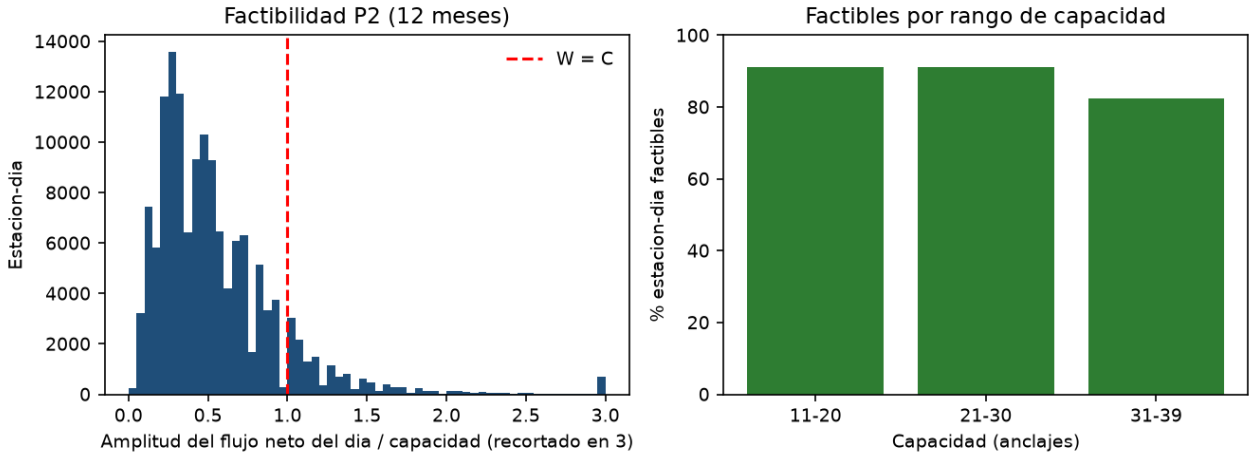


Figura 2. Amplitud del flujo neto frente a capacidad y factibilidad por rango de capacidad (EDA).

2.4 Condiciones de uso y datos personales

- **Licencia:** el portal dice "explora, experimenta y comparte los datos", pero no publica una licencia específica ni condiciones de reuso para los CSV. Tratamiento: uso académico con atribución a MiBici. **Punto abierto:** confirmar con la AMIM antes de publicar resultados fuera del curso.
- **Datos personales:** `Usuario_Id`, género y año de nacimiento son datos personales asociados a usuarios. El tratamiento del equipo es: no usar estas columnas como variables ni publicarlas; no registrar ningún dato a nivel de usuario en MLflow ni en Git; mantener los datos crudos fuera del repositorio (`data/` está ignorado por Git); y mostrar resultados solo agregados por estación u hora.

2.5 Partición y cómo evitamos usar información del futuro

Conjunto	Meses	Viajes	Uso
Entrenamiento	Octubre de 2025 a junio de 2026 (9)	3,226,040	Ajuste de modelos y transformaciones (medias, escalas, clusters de P3)
Validación	Julio y agosto de 2026 (2)	781,781	Selección de modelo e hiperparámetros
Prueba	Septiembre de 2026 (1)	490,056	Una sola evaluación final

Reglas para no usar el futuro:

- Partición cronológica. Nunca aleatoria.
- Validación cruzada dentro de entrenamiento con `TimeSeriesSplit` (5 pliegues) y un hueco (purga) de 24 h en P1 y de `H` horas en P2.
- Todas las transformaciones (escalas, imputaciones y clusters de P3) se ajustan solo con entrenamiento y después se aplican a validación y prueba.
- En P1 solo se usan rezagos de 24 h o más. En P2 solo se usa el flujo acumulado hasta `t`, no el del día completo.
- La etiqueta de P2 puede mirar al futuro; las variables no.
- El conjunto de prueba se abre una sola vez por pregunta.

3. Pipeline de ML por pregunta

Flujo común a las tres preguntas:

- Ingesta (dataset.py): descarga de los 12 CSV y de la nomenclatura, detección de codificación, normalización de columnas y fechas, eliminación de duplicados, guardado en Parquet y manifiesto con número de registros y SHA-256 por archivo, y data_version como identificador de la versión de datos. Implementado y ejecutado.
- **Limpieza:** reglas de la sección 2.3.
- **Agregación:** panel estación-hora con salidas, llegadas y flujo neto; panel de estaciones para P3.
- Ingeniería de variables (features.py): calendario (hora, día de la semana, mes, festivo oficial de México, fin de semana); rezagos y medias de 24 h o más (salidas a 24, 48 y 168 h; promedio de las últimas cuatro semanas para el mismo día y hora); capacidad y cluster de P3 ajustado solo con entrenamiento; y para P2, el flujo acumulado F(t), llegadas y salidas de la última y las dos últimas horas, salidas de la misma hora del día anterior y capacidad.
- **Entrenamiento:** solo con entrenamiento; selección en validación.
- Evaluación: una sola vez con prueba. Cada corrida se registra en MLflow con data_version, git_commit y git_dirty (paso 6 completado).

Variable	Pregunta	Por qué es pertinente
Hora y día de la semana	P1, P2	El perfil de demanda tiene picos a las 08:00 y 18:00 y un patrón laboral (EDA).
Festivos	P1	Cambian el patrón y se conocen de antemano.
Salidas a 24, 48 y 168 h	P1	Repiten el patrón diario y semanal, y son observables al emitir el pronóstico.
Capacidad	P1, P2	Limita el máximo de bicicletas y de anclajes.
Flujo acumulado $F(t)$	P2	Es lo único del día que se conoce hasta t y se acerca al inventario.
Cluster de P3	P1	Agrupa estaciones con patrón parecido y comparte información entre ellas.

4. Baselines, modelos y métricas

Cada pregunta tiene un baseline sencillo, al menos un modelo candidato y métricas nombradas con el conjunto de datos (por ejemplo test_mae). Justificamos las métricas con la guía de evaluación de scikit-learn (scikit-learn developers, s.f.). Para P1, la literatura de MiBici predice demanda diaria con series de tiempo (Briseño et al., 2020), y otros trabajos pronostican demanda horaria con flujo neto (Hosseinpanahi et al., 2026).

4.1 P1: regresión de conteos

Rol	Modelo	Por qué
Baseline 1	Estacional-ingenuo: salidas de hace 168 h	Es el benchmark de series de tiempo más simple que captura el patrón semanal.
Baseline 2	Promedio histórico por estación, día de la semana y hora, de las últimas 4 semanas	Benchmark más fuerte y sin ajuste.
Candidato 1	`PoissonRegressor` (scikit-learn) con variables codificadas	Modelo lineal de conteos e interpretable.
Candidato 2	`HistGradientBoostingRegressor(loss="poisson")`	Captura no linealidades e interacciones.

		La pérdida de Poisson es adecuada para conteos (Schimohr et al., 2023).

Métrica (prueba)	Qué mide	Por qué
test_mae	Error absoluto medio por estación-hora	Fácil de explicar al operador.
test_rmse	Error cuadrático medio (raíz)	Penaliza los picos grandes; útil para dimensionar la reserva.
test_poisson_deviance	Desviación de Poisson	Pérdida natural para conteos; compara la media estimada.
test_wape	Suma de errores absolutos entre suma de observados	Se usa en lugar de MAPE porque 62.29% de las celdas son cero y MAPE no está definido ahí.

Limitación: la varianza es cinco veces la media (índice de dispersión 5.03), así que Poisson no describe bien la incertidumbre. Si se requieren intervalos, evaluaremos binomial negativa, como comparan Schimohr et al. (2023).

Resultados. P1 solo tiene dos baselines en el repositorio; no hay un modelo candidato aprendido. La media de cuatro semanas se seleccionó por WAPE en validación y es la referencia de prueba. El baseline de 168 h sigue la comparación con el valor de hace una semana descrita en Minimize Regret (2022). Cifras por estación-hora en viajes (fuente: reports/tables/p1_metrics.csv).

Baseline	Partición	MAE	RMSE	WAPE	Sesgo
Semana anterior (168 h)	Validación	0.9287	1.8594	76.12 %	-0.0049
Media de cuatro semanas	Validación	0.8011	1.5052	65.67 %	-0.0160
Semana anterior (168 h)	Prueba	1.0297	2.1127	71.01 %	-0.1173
Media de cuatro semanas	Prueba	0.8806	1.7412	60.73 %	-0.2236

4.2 P2: clasificación de riesgo

Rol	Modelo	Por qué
Baseline 1	Clase mayoritaria	Cota inferior obligatoria; con clase rara da alta exactitud sin valor.
Baseline 2	Persistencia: r(s, t-H)	El riesgo observado en la ventana anterior; sin ajuste.
Candidato 1	LogisticRegression(class_weight="balanced")	Lineal y calibrable.
Candidato 2	HistGradientBoostingClassifier	Captura interacciones entre hora, flujo acumulado y capacidad.

La decisión es priorizar visitas, así que importa el ranking en la parte alta (PR-AUC y precisión en k), no la exactitud global.

Resultados en validación (2026-07 a 2026-08) de los cuatro modelos. El modelo final se eligió por la regla pre-declarada: mejor modelo aprendido en PR-AUC de validación. Fuente: reports/tables/p2_metrics.csv.

Modelo	PR-AUC val.	ROC-AUC val.	Brier val.	Precisión@10 % val.
HistGradientBoosting	0.0624	0.8701	0.0037	0.0207
Regresión logística	0.0123	0.7722	0.2038	0.0128
Persistencia r(s, t-H)	0.1228	0.6654	0.0048	0.0198
Mayoritaria	0.0038	0.5000	0.0038	0.0108

Lectura honesta: en PR-AUC de validación la persistencia (0.1228) supera a todos los modelos aprendidos; hist_gb (0.0624) es el mejor de ellos y su ROC-AUC (0.8701) es el más alto. Por eso no conviene leer el modelo final como superior a la persistencia.

Prueba (abierta una sola vez, run 0281eb79, commit b8651e1, data_version 0f000bd5…): PR-AUC 0.0733, ROC-AUC 0.8561, Brier 0.0051, precisión@10 % 0.0279, recall con precisión ≥ 0.5 0.0088.

Limitación de reproducibilidad: el hash de stations.parquet generado localmente no coincide con el del manifiesto publicado, aunque los 12 Parquet de viajes sí coinciden. P2 lo registra como advertencia en el artefacto del run y no detiene la ejecución.

4.3 P3: clustering de estaciones

Rol	Modelo	Por qué
Baseline	K-Means sobre latitud y longitud	Agrupa por cercanía geográfica sin considerar el uso.
Candidato 1	K-Means sobre perfil de uso estandarizado y PCA	Agrupa por patrón de uso.
Candidato 2	Mezcla de gaussianas (GMM)	Permite clusters de distinta forma y tamaño.
Candidato 3	Clustering aglomerativo (Ward)	No supone clusters esféricos; sirve para comparar jerarquías.

Métrica (entrenamiento)	Qué mide	Por qué
silhouette_score	Cohesión y separación de los grupos (−1 a 1; mayor es mejor)	Principal criterio para elegir k.
davies_bouldin_score	Dispersión intra frente a separación inter grupo (menor es mejor)	Penaliza grupos dispersos o cercanos entre sí.
calinski_harabasz_score	Razón entre dispersión inter e intra grupo (mayor es mejor)	Compara configuraciones de k.

Métricas internas, calculadas sobre el conjunto de entrenamiento: silhouette_score, calinski_harabasz_score y davies_bouldin_score, registradas en MLflow. El número de grupos k se elige entre 3 y 8 con estas tres métricas, no con una sola. El artefacto es el mapa de estaciones coloreado por cluster, en reports/figures/.

4.3.1 Baseline exploratorio ejecutado

Baseline exploratorio ejecutado. El uso de K-Means con viajes de MiBici para caracterizar zonas tiene antecedente en Gracia-Rivera y Villalón-Turrubiates (2022). Se implementó un baseline de K-Means con una observación por estación, utilizando la tabla agregada reports/tables/estaciones_resumen.csv. Las variables de entrada fueron log1p(salidas_12m), log1p(llegadas_12m) y la capacidad modelada, estandarizadas con StandardScaler. Los identificadores, nombres y

coordenadas no se utilizaron para ajustar el modelo; la latitud y longitud se reservaron exclusivamente para visualizar la distribución de los grupos en la ciudad.

La tabla contiene 484 estaciones. Cuatro presentan capacidad igual a cero. Debido a que ese valor no resulta utilizable como capacidad operativa para el clustering, se conservó la capacidad original para trazabilidad y se creó capacidad_modelo, sustituyendo únicamente esos cuatro valores por la mediana de las capacidades estrictamente positivas. La columna capacidad_imputada identifica las observaciones tratadas. Esta decisión es provisional y deberá revisarse cuando la ingesta reproducible permita investigar el origen de esos valores.

Comparación de configuraciones K-Means para P3

k	Inercia	Silhouette	Calinski-Harabasz	Davies-Bouldin	Mínimo	Máximo
3	600.9440	0.3670	340.5957	0.8422	15	293
4	344.7089	0.4597	513.9599	0.6648	15	194
5	**259.9117**	**0.4703**	**549.2349**	**0.6152**	**11**	**194**
6	202.0845	0.4639	591.3601	0.6506	11	140
7	167.1542	0.4774	611.1147	0.6809	9	130
8	135.8448	0.5174	658.8294	0.6434	11	108

Se seleccionó k=5 para el baseline. Aunque k=8 obtuvo el mayor coeficiente de silueta y el mayor índice Calinski-Harabasz, k=5 alcanzó el menor índice Davies-Bouldin y produjo una segmentación más parsimoniosa e interpretable. Los cinco grupos distinguen estaciones sin actividad observada, estaciones de bajo volumen, dos perfiles intermedios diferenciados por uso y capacidad, y un grupo de muy alto volumen y alta capacidad. La elección prioriza la utilidad operativa y la claridad del baseline, sin afirmar que k=5 sea la única solución válida.

Perfil agregado de los clusters seleccionados

Cluster	Estaciones	Capacidad media	Salidas medias	Llegadas medias	Interpretación
0	194	14.01	11,056	10,825	Uso medio y capacidad baja
1	15	15.27	0	0	Sin actividad observada
2	140	20.09	13,473	13,803	Uso medio-alto y capacidad media
3	124	17.19	1,082	943	Bajo volumen
4	11	30.91	30,065	31,497	Muy alto volumen y alta capacidad

Las etiquetas son descripciones operativas derivadas de los agregados disponibles. “Sin actividad observada” no implica que las estaciones estuvieran cerradas o fuera de servicio; solo indica ausencia de viajes en el periodo analizado.

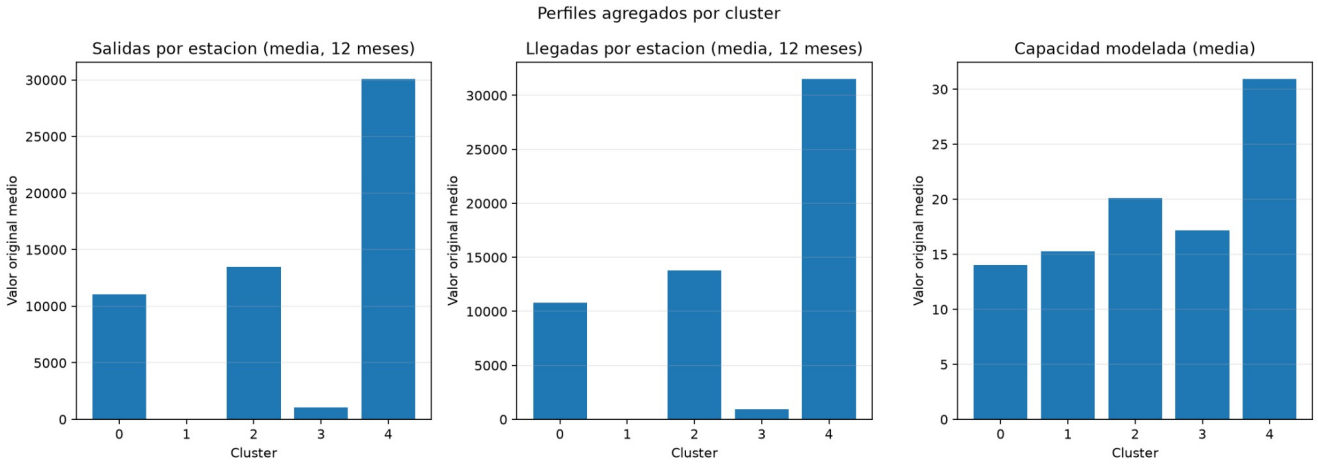


Figura 3. Perfiles agregados de los cinco clusters seleccionados. Las barras muestran el promedio de salidas, llegadas y capacidad modelada por grupo. Los valores de viajes corresponden a agregados de octubre de 2025 a septiembre de 2026.

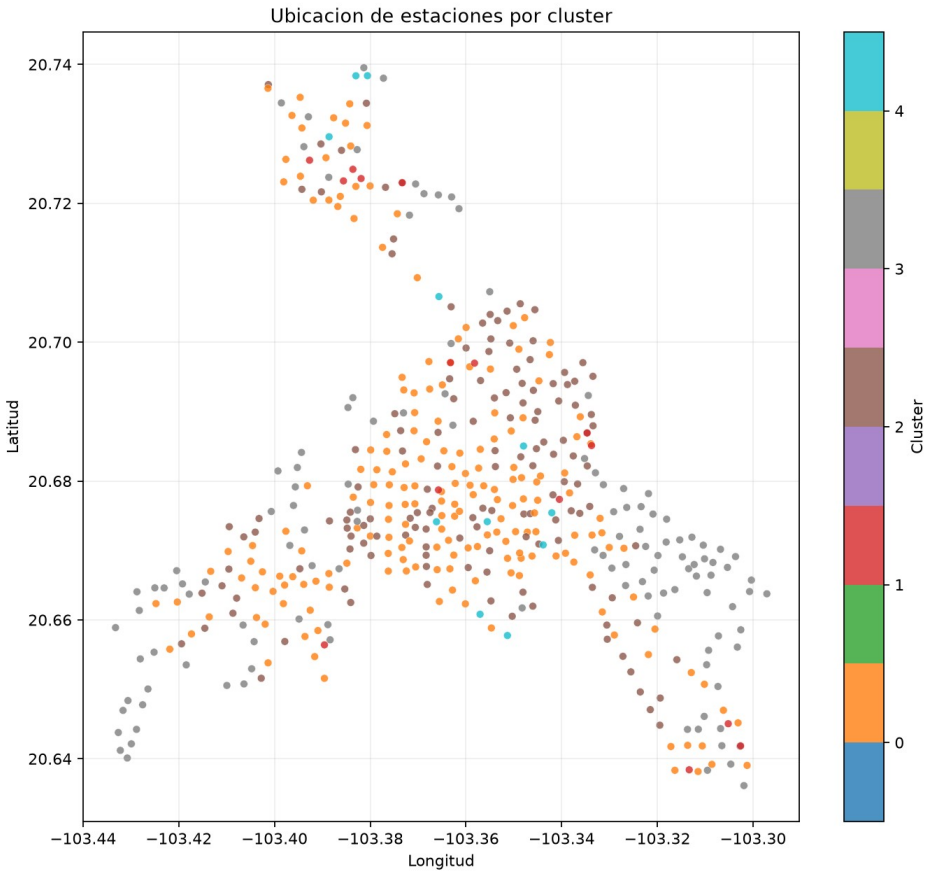


Figura 4. Distribución espacial de las estaciones según el cluster seleccionado (k=5). Las coordenadas se utilizaron solamente para visualización y no como variables del modelo. La mezcla espacial de colores indica que los grupos describen perfiles de uso y capacidad, no regiones geográficas compactas.

Limitaciones. Este experimento es un baseline exploratorio construido con agregados de los 12 meses completos. Por ello, no utiliza el perfil horario por estación propuesto para la versión final, no cuenta con una partición temporal independiente y no debe interpretarse como validación fuera de muestra. La implementación final deberá reconstruir las features únicamente con el periodo de entrenamiento, incorporar patrones horarios y evaluar la estabilidad de los grupos en validación y prueba.

5. Experimentos base en MLflow

5.1 Run P1: Regresión

Runs P1 registrados en el experimento mibici-equipo49: un run por baseline (media de cuatro semanas seleccionada por validación; estacional de 168 h como referencia). Fuente: reports/tables/p1_runs.json.

Elemento	Valor
P1-media-4semanas	run_id 15d5969c45f54aadb44b80b8f0aa8563 · test_mae 0.8806 · test_wape 60.73 % · git_commit 52af95c
P1-estacional-168h	run_id afb77ec9c5904efd9e9c059376d7b90b · test_mae 1.0297 · test_wape 71.01 % · git_commit 52af95c

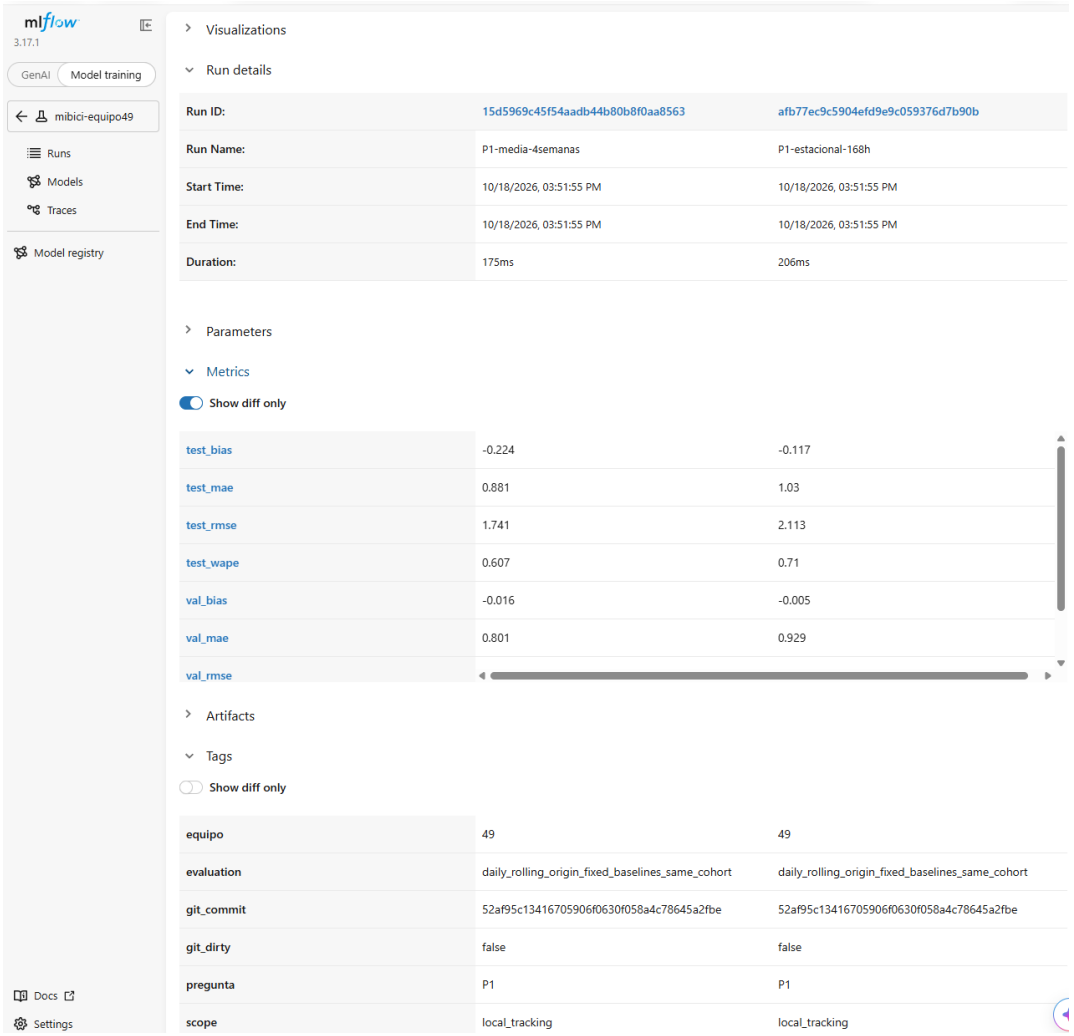


Figura 5. Captura de MLflow de los dos runs P1 en mibici-equipo49 (Saúl Salgado): P1-media-4semanas y P1-estacional-168h, con métricas de prueba (test_mae, test_rmse, test_wape, test_bias) y de validación (val_*), y git_commit 52af95c.

5.2 Run P2: Clasificación

Run final de P2 registrado desde el código del repositorio. Los runs de validación (persistencia, logística, mayoritaria e hist_gb) comparten commit y data_version. Las cinco capturas se tomaron en MLflow.

Elemento	Valor
Experimento	mibici-equipo49
Run final	P2-hist_gb-final (0281eb7986974d7e8536dbacdfda2a9f)
Estado	FINISHED
Commit Git	b8651e14920789b72e648ce538e4c5953f0a1e0e
Rama	feat/p2-integracion-cierre
git_dirty	false
data_version	0f000bd5e6563196d7c1133e119024e4e864f6325752e4f6b48e40011895d1a3
Modelo	HistGradientBoostingClassifier (hist_gb), semilla 42
Horizonte H	2 horas
Ventana de prueba	2026-09-01 a 2026-09-30 (abierta una sola vez)

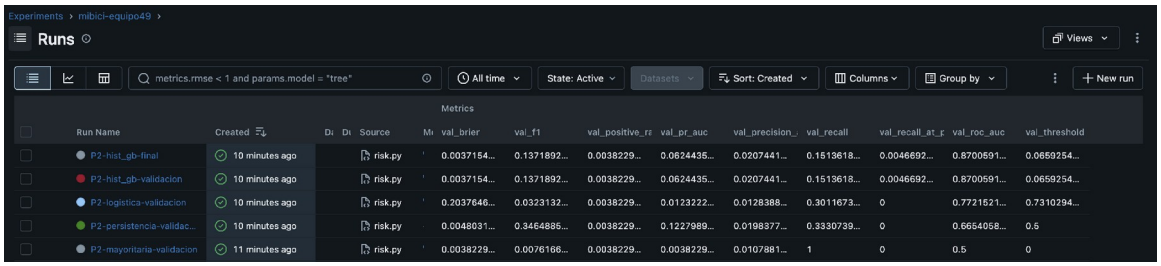


Figura 6. Lista de runs de P2 en mibici-equipo49, con las métricas de validación.

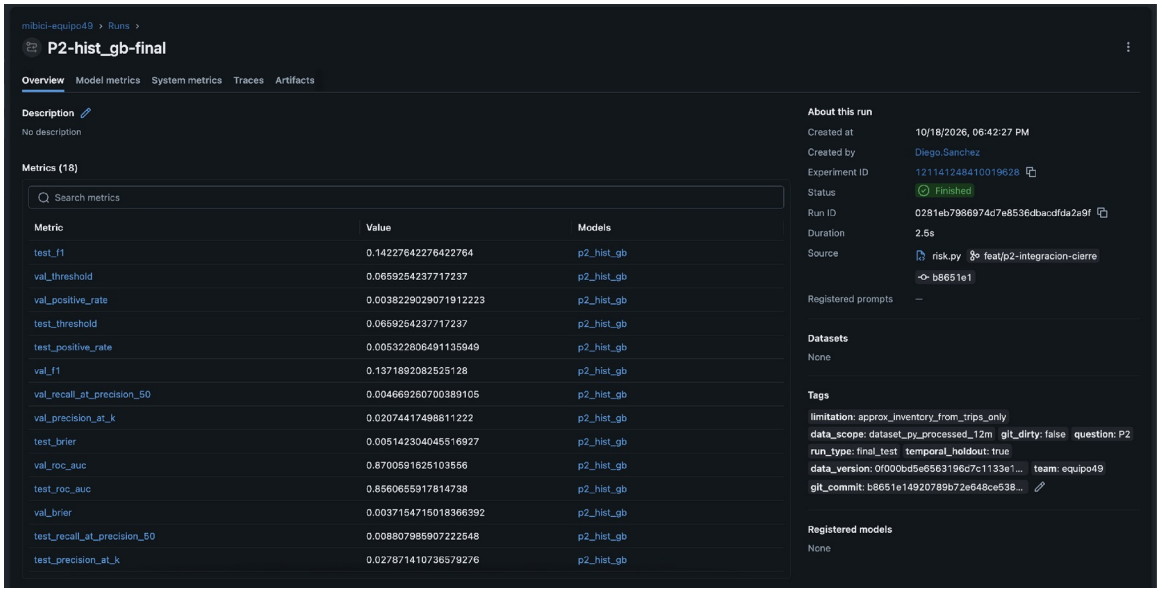


Figura 7. Detalle del run final P2-hist_gb-final: métricas de validación y prueba, etiquetas team, question, git_commit, git_dirty y data_version.

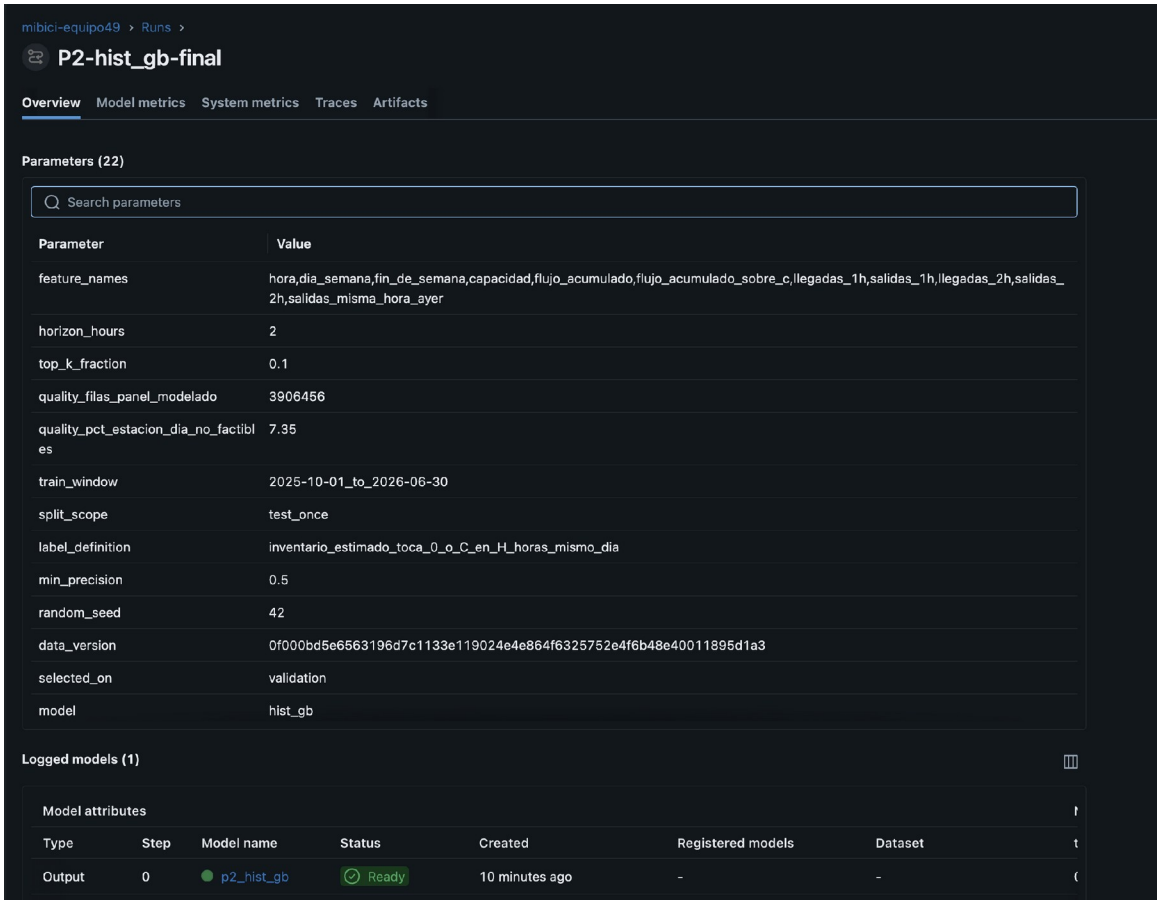


Figura 8. Parámetros del run final: ventanas temporales, semilla, horizonte, data_version y calidad de datos.

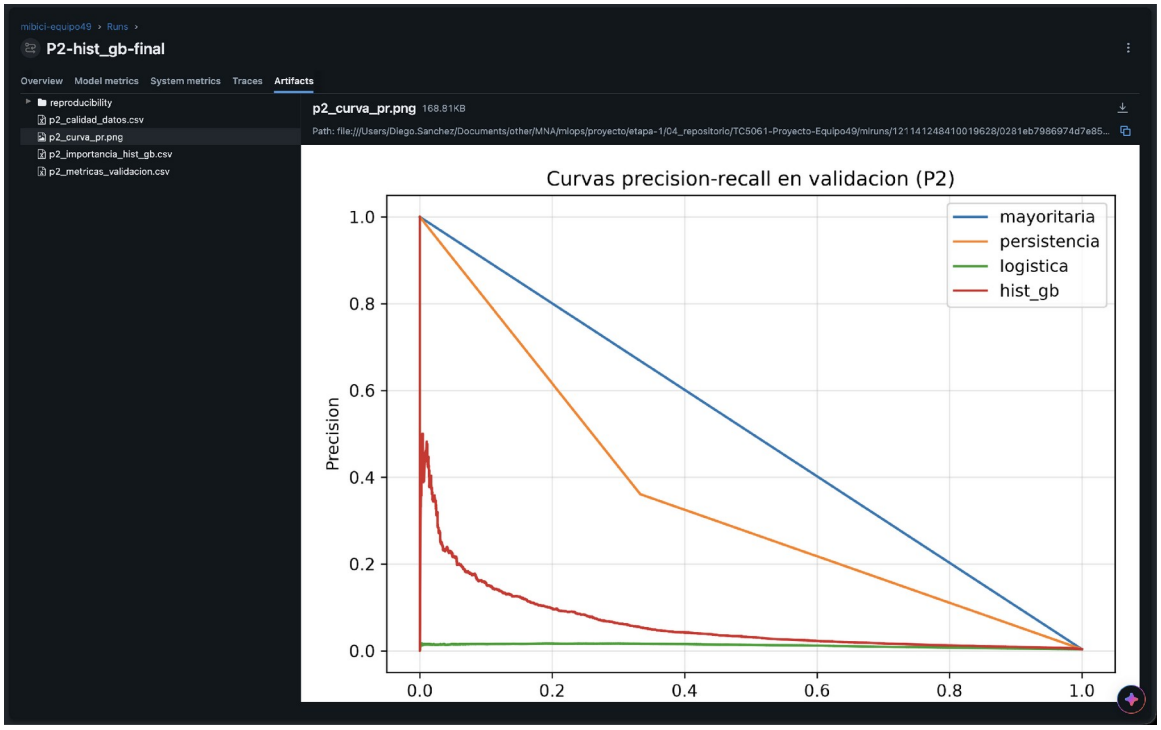


Figura 9. Artefacto del run: curva precision-recall en validación (p2_curva_pr.png) y tablas de calidad e importancia.

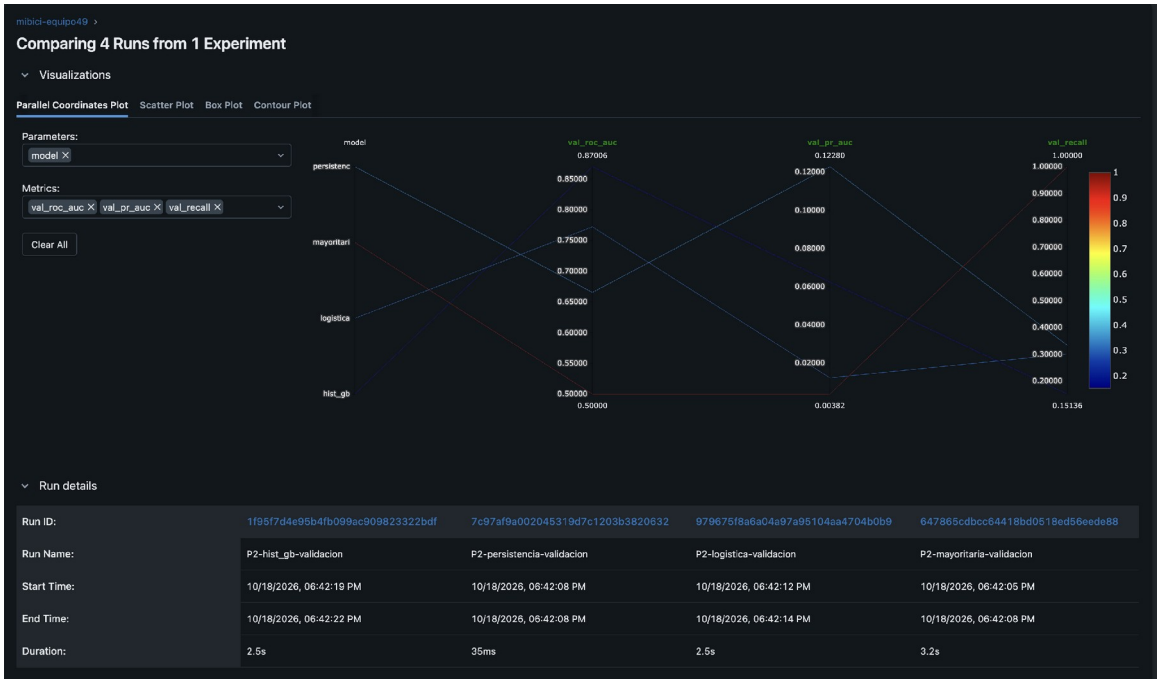


Figura 10. Comparación de los cuatro runs de validación (persistencia, logística, mayoritaria e hist_gb) con coordenadas paralelas.

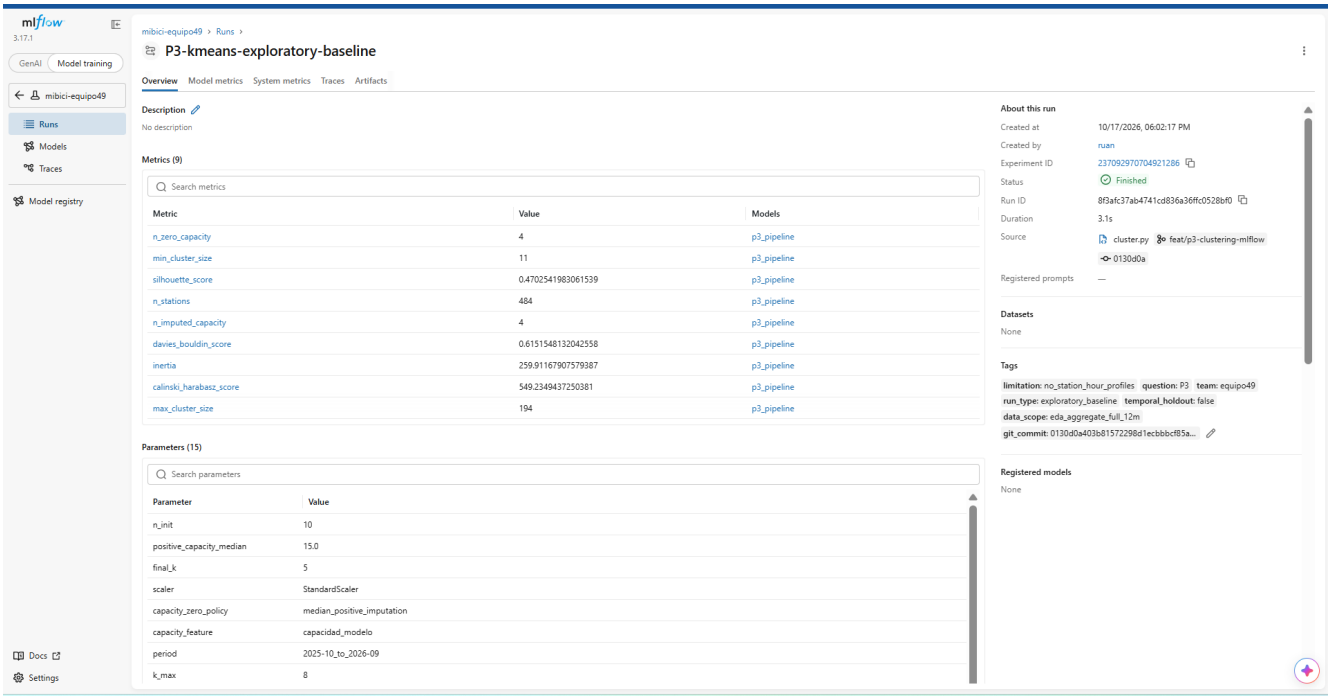
5.3 Run P3: clustering exploratorio

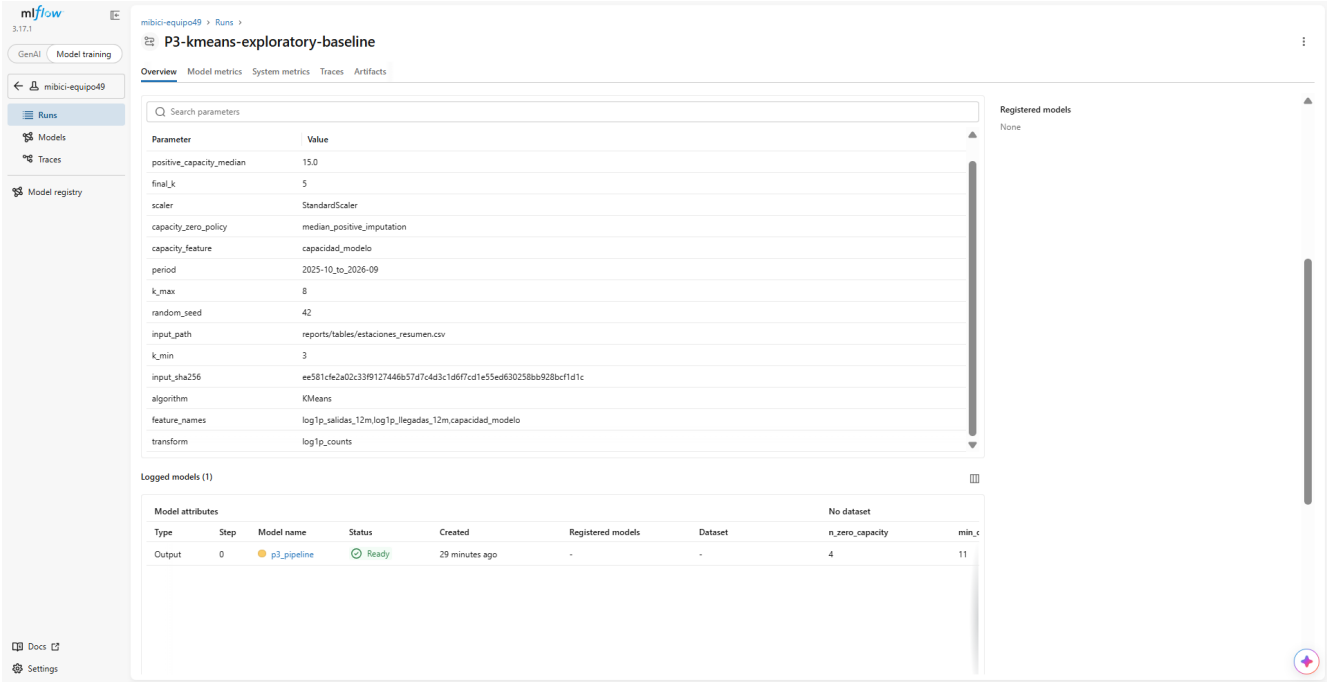
El baseline P3 se ejecutó desde el módulo mibici_ml.modeling.cluster y se registró en el experimento mibici-equipo49. El run utiliza semilla 42, final_k=5, la versión agregada de 12 meses y el hash SHA-256 del archivo de entrada. Se registraron

parámetros, métricas internas, etiquetas de equipo, pregunta y commit de Git, el pipeline StandardScaler + KMeans y siete artefactos.

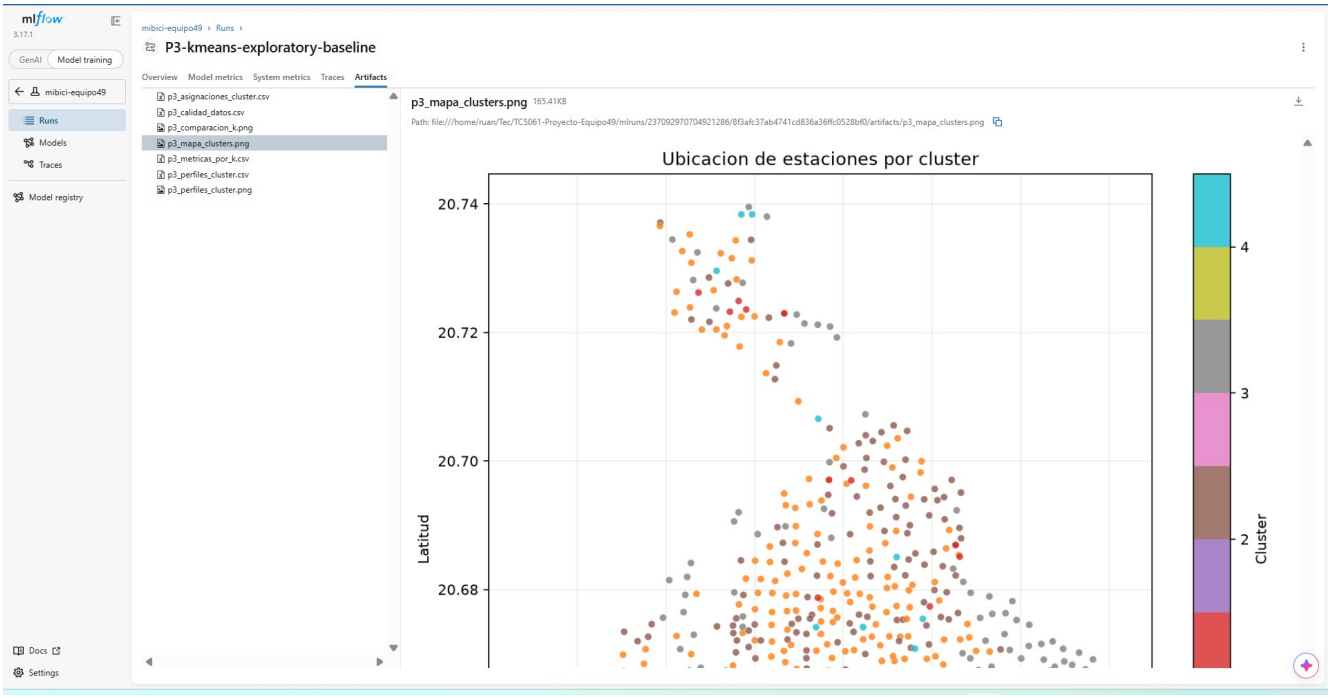
Elemento	Valor
Experimento	mibici-equipo49
Run	P3-kmeans-exploratory-baseline
Run ID	**8f3afc37ab4741cd836a36ffc0528bf0**
Estado	FINISHED
Commit Git	**0130d0a403b81572298d1ecbbbcf85aa028836ba**
Rama	feat/p3-clustering-mlflow
Modelo	StandardScaler + KMeans
final_k	5
Semilla	42
Silhouette	0.470254
Calinski-Harabasz	549.234944
Davies-Bouldin	0.615155
Inercia	259.911679
Estaciones	484
Capacidades imputadas	4
Artefactos	7

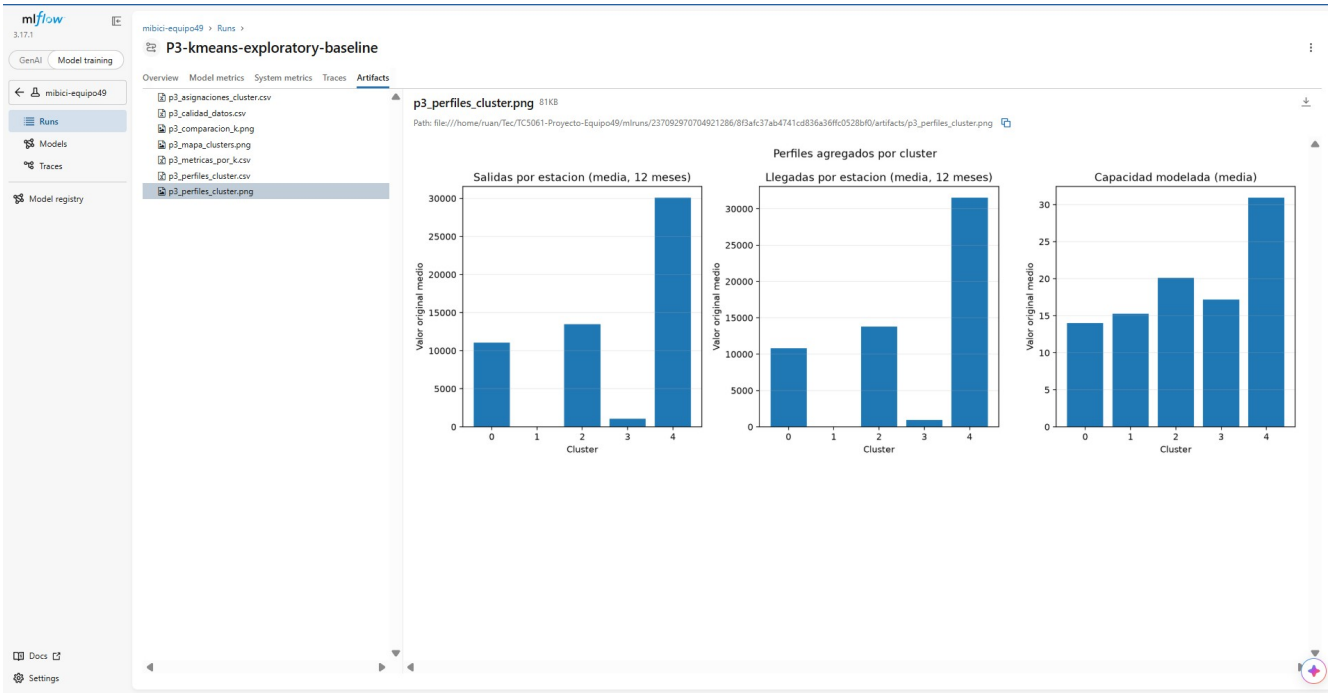
Las siguientes capturas presentan el detalle del run registrado en MLflow, incluyendo parámetros, métricas, etiquetas, estado de ejecución y referencia al código fuente. Además de confirmar el registro y visualización del mapa de clusters como artefacto del mismo run.





Figuras 11 y 12. Detalle del run P3 registrado en MLflow. El run P3-kmeans-exploratory-baseline registra las métricas internas del clustering, los parámetros de KMeans con final_k=5, la política de tratamiento de capacidades iguales a cero y las etiquetas de trazabilidad correspondientes al Equipo 49, la pregunta P3 y el commit de Git 0130d0a403b81572298d1ecbbbcf85aa028836ba.





Figuras 13 y 14. Artefactos espaciales de P3 registrado en MLflow. La interfaz muestra el archivo p3_mapa_clusters.png y p3_perfiles_cluster.png dentro de los artefactos del run. Los colores representan los cinco clusters seleccionados para las 484 estaciones. La ubicación geográfica se utilizó exclusivamente para visualización y no como variable de entrada de KMeans.

6. Arquitectura del sistema

El diagrama está en references/arquitectura_mibici_equipo49.png (fuente en 03_entregables/diagrama/arquitectura_mibici_equipo49.py). Las herramientas siguen la documentación de MLflow (MLflow, s.f.) y de scikit-learn (scikit-learn developers, s.f.). Muestra las fuentes, la ingesta, el almacenamiento, el procesamiento, el entrenamiento y el registro de experimentos, junto con el flujo de colaboración.

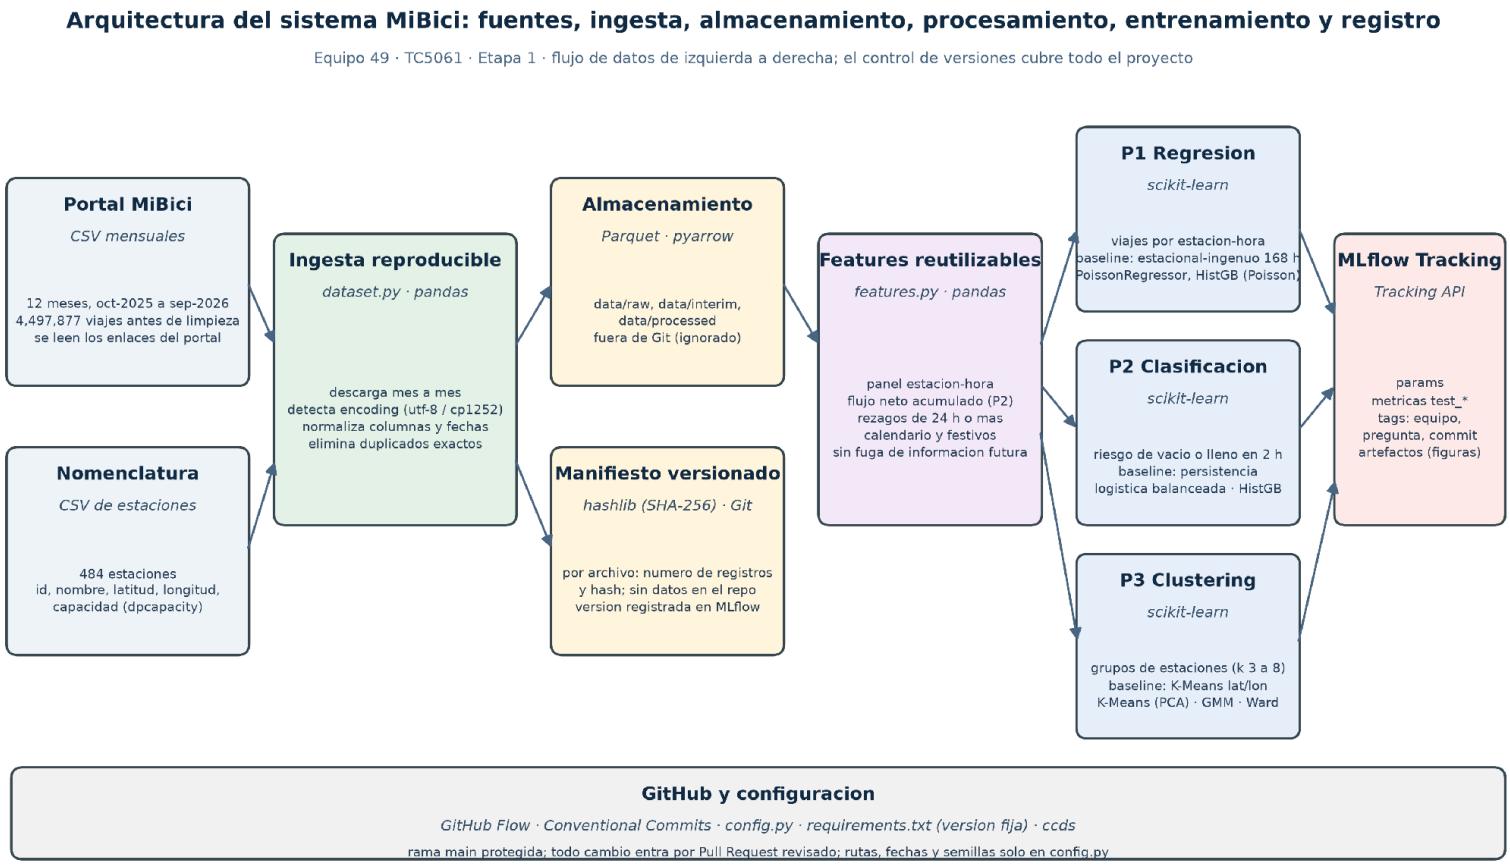


Figura 15. Arquitectura del sistema: fuentes, ingesta, almacenamiento, procesamiento, entrenamiento, MLflow y GitHub.

Componente	Herramienta	Justificación
Fuente de datos	Portal MiBici (CSV mensuales) y nomenclatura	Fuente oficial, mensual y sin API. Se leen los enlaces de la página porque los IDs cambian.
Ingesta	dataset.py con requests, hashlib y pandas	Ejecutable desde la terminal. El manifiesto con SHA-256 versiona los datos.
Almacenamiento	Parquet en data/raw, data/interim y data/processed; manifiesto en Git	Formato columnar eficiente. El manifiesto es un registro ligero y versionable (versionado de datos, Treveil et al., 2020).
Procesamiento	features.py con pandas y pyarrow	Transformaciones reutilizables y documentadas.
Entrenamiento	scikit-learn	Guía oficial para supervisado, clustering y evaluación; los mismos estimadores sirven para baselines y candidatos.
Registro de experimentos	MLflow Tracking	Guarda parámetros, métricas, etiquetas, artefactos y el commit de cada corrida (documentación de MLflow).
Colaboración y control de versiones	Git, GitHub Flow y Conventional Commits	Rama principal protegida, PR revisado y convención de mensajes.
Estructura del proyecto	Cookiecutter Data Science (ccds)	Separación estándar de datos, notebooks, módulo, modelos y figuras (Huyen, 2022).
Entorno	uv con Python 3.12 y requirements.txt con versiones fijas	Entorno reproducible desde un clon limpio.

Alternativas descartadas por ahora:

- Orquestador (Airflow o Prefect): no hace falta para una ejecución mensual. Se reconsidera si el pipeline se automatiza.
- DVC: versiona datos con más detalle, pero agrega otra herramienta. Usamos el manifiesto que pide la actividad; DVC queda como opción.
- Weights & Biases: alternativa a MLflow, pero el curso usa MLflow.

Las citas a libros (Treveil et al., 2020; Huyen, 2022; Wilson, 2022) se hacen a nivel de libro, sin capítulo ni página, porque el equipo no tiene a la mano los capítulos de las lecturas del curso.

7. Estructura base del repositorio

Repositorio público: https://github.com/dieguini95/TC5061-Proyecto-Equipo49. Se llama TC5061-Proyecto-Equipo49, como pide la actividad.

7.1 Cómo se generó

- Generado con ccds (cookiecutter-data-science) de forma no interactiva, con include_code_scaffold=Yes, Python 3.12, virtualenv, requirements.txt, pydata básico, pytest, ruff, licencia MIT y el módulo mibici_ml.
- El primer commit es la salida pura de ccds, como exige la actividad. Los commits siguientes agregan la configuración, las dependencias, las referencias, el notebook y la documentación.
- Credenciales: el repositorio se creó y se empujó con un token de GitHub guardado en el archivo .env del proyecto. El token no está en el repositorio, en .git/config ni en el historial.

7.2 Estructura de carpetas

Árbol de archivos versionados en la rama main (generado con git ls-files). Los datos, mlruns, modelos y .env no aparecen porque están fuera de Git.

```
TC5061-Proyecto-Equipo49/
├── .github/
│   └── pull_request_template.md
├── docs/
│   └── .gitkeep
├── mibici_ml/
│   ├── modeling/
│   │   ├── __init__.py
│   │   ├── cluster.py
│   │   ├── demand.py
│   │   ├── predict.py
│   │   ├── risk.py
│   │   └── train.py
│   ├── __init__.py
│   ├── config.py
│   ├── dataset.py
│   ├── features.py
│   └── plots.py
├── models/
│   └── .gitkeep
├── notebooks/
│   ├── .gitkeep
│   ├── 1.0-dsh-eda-inicial.ipynb
│   └── 1.0-sso-eda-p1.ipynb
├── references/
│   ├── .gitkeep
│   ├── ML_Canvas_MiBici_Equipo49.docx
│   ├── ML_Canvas_MiBici_Equipo49.pdf
│   ├── P1_propuesta_y_resultados.md
│   ├── TC5061_Propuesta_Proyecto_Equipo49.docx
│   ├── arquitectura_mibici_equipo49.png
│   └── data_manifest.json
├── reports/
│   ├── figures/
│   │   ├── .gitkeep
│   │   ├── P1_daily_totals.png
│   │   ├── P1_error_comparison.png
│   │   ├── P1_mlflow_artifact.png
│   │   ├── P1_mlflow_comparison.png
│   │   ├── P1_mlflow_detail.png
│   │   ├── P1_mlflow_metrics.png
│   │   ├── P1_mlflow_runs.png
│   │   ├── P1_station_example.png
│   │   ├── P2_mlflow_artifact.png
│   │   ├── P2_mlflow_comparison.png
│   │   ├── P2_mlflow_detail.png
│   │   ├── P2_mlflow_metrics.png
│   │   ├── P2_mlflow_runs.png
│   │   ├── P2_pr_curve.png
│   │   ├── duracion_viajes.png
│   │   ├── factibilidad_p2.png
│   │   ├── heatmap_dia_hora.png
│   │   ├── mapa_estaciones.png
│   │   ├── perfil_horario.png
│   │   └── volumen_diario.png
│   └── tables/
│       ├── estaciones_resumen.csv
│       ├── factibilidad_p2_por_capacidad.csv
│       ├── inventario_meses.csv
│       ├── p1_metrics.csv
│       ├── p1_quality.json
│       ├── p1_runs.json
│       ├── p1_station_metrics.csv
│       ├── p2_metrics.csv
│       ├── p2_runs.json
│       ├── perfil_dia_hora.csv
│       ├── resumen.json
│       └── volumen_diario.csv
│   └── .gitkeep
├── tests/
│   ├── test_clustering.py
│   ├── test_config.py
│   ├── test_dataset.py
│   ├── test_demand.py
│   ├── test_features.py
│   └── test_risk.py
├── .gitignore
├── LICENSE
├── Makefile
├── README.md
├── pyproject.toml
├── requirements-p1.lock.txt
└── requirements.txt
```

Figura 16. Estructura del repositorio TC5061-Proyecto-Equipo49 (archivos versionados).

Carpeta o archivo	Contenido	Regla
data/ (raw, interim, processed, external)	Datos de MiBici generados por la ingesta	No se versiona (.gitignore).
notebooks/	1.0-dsh-eda-inicial.ipynb: EDA con agregados	Solo exploración. Nombre 1.0-iniciales-descripcion.ipynb.
mibici_ml/	Código del módulo: config.py, dataset.py, features.py, plots.py, modeling/	Lógica final en el módulo.
mibici_ml/config.py	Rutas, fuentes, ventana temporal, cortes de partición, semilla, nombre del experimento y parámetros de P1 a P3	Configuración en un solo lugar.
models/	Modelos serializados	No se versionan.
reports/figures/, reports/tables/	Figuras y tablas agregadas del EDA	Solo agregados, sin datos a nivel viaje ni usuario.
references/	ML Canvas (DOCX y PDF) y diagrama de arquitectura (PNG)	Material de la Etapa 1.
tests/	test_config.py valida la configuración temporal; test_clustering.py valida el contrato de datos, tratamiento de capacidad cero, reproducibilidad, métricas, artefactos y tracking temporal de MLflow para P3.	Pruebas con pytest.
requirements.txt	173 líneas con versiones fijas (incluye pandas==3.0.6, pyarrow==25.0.1, scikit-learn==1.9.1, mlflow==3.17.1)	Resueltas en un venv limpio de Python 3.12.13.
.gitignore	Datos, mlruns/, mlartifacts/, .env, modelos serializados (*.pkl, *.joblib, *.pt), bases de datos	Excepción: reports/tables/*.csv, que son agregados.
.github/pull_request_template.md	Plantilla de PR: tipo de cambio, pruebas, experimentos y revisión	Usa Conventional Commits.

7.3 Historial de commits

Commit	Mensaje
44fa5f3	Merge pull request #3 from dieguini95/Saul
0a08196	Merge pull request #2 from dieguini95/feat/p2-risk-mlflow
b26a9db	docs(p1): actualiza evidencia reproducible y resultados del experimento
52af95c	feat(p1): agrega demanda estacion-hora con ingesta versionada y MLflow
ba341d8	docs(p2): document risk baseline workflow and limitations
9a8e780	test(p2): cover risk labels, feasibility, leak-free features and MLflow
25cf647	feat(p2): add station risk classifier with MLflow tracking
fee9703	Merge pull request #1 from dieguini95/feat/p3-clustering-mlflow
0130d0a	docs(p3): document baseline workflow and limitations
5c46e83	test(p3): cover clustering pipeline and MLflow tracking
72d6122	feat(p3): add exploratory station clustering baseline

e7d1dd1	docs: esqueleto de README (paso 12) y plantilla de Pull Request

7.4 Protección de la rama principal

- La rama main requiere Pull Request con una aprobación, conversaciones resueltas y no permite force push ni borrado. Todos los PR fusionados tuvieron aprobación de un integrante distinto a su autor.
- Los administradores no están obligados por la regla: el dueño del repositorio puede fusionar sin una segunda aprobación. Es una decisión del equipo para no bloquear la entrega.

7.5 Verificación del entorno

En un clon limpio de main (commit 37153a4), con Python 3.12 y las dependencias de requirements.txt: pytest pasa 81 pruebas (configuración, ingesta, features, baseline P1, baseline P3 y P2). ruff check no reporta errores; ruff format --check reporta un archivo pendiente en cluster.py (P3).

7.6 Pull requests de colaboradores

Pull requests del proyecto, con autor y revisión aprobada según GitHub. Cada integrante debe abrir al menos un PR y revisar al menos uno de otro integrante.

PR	Rama	Autor (GitHub)	Revisión aprobada por	Estado
#1	feat/p3-clustering-mlflow	DaniRuan (Daniel Ruán)	dieguini95 (Diego Sánchez)	Fusionado
#2	feat/p2-risk-mlflow	dieguini95 (Diego Sánchez)	DaniRuan (Daniel Ruán)	Fusionado
#3	Saul	Drezneck-RM (Saúl Salgado)	dieguini95 (Diego Sánchez)	Fusionado
#4	feat/p2-integracion-cierre	dieguini95 (Diego Sánchez)	Drezneck-RM (Saúl Salgado)	Fusionado

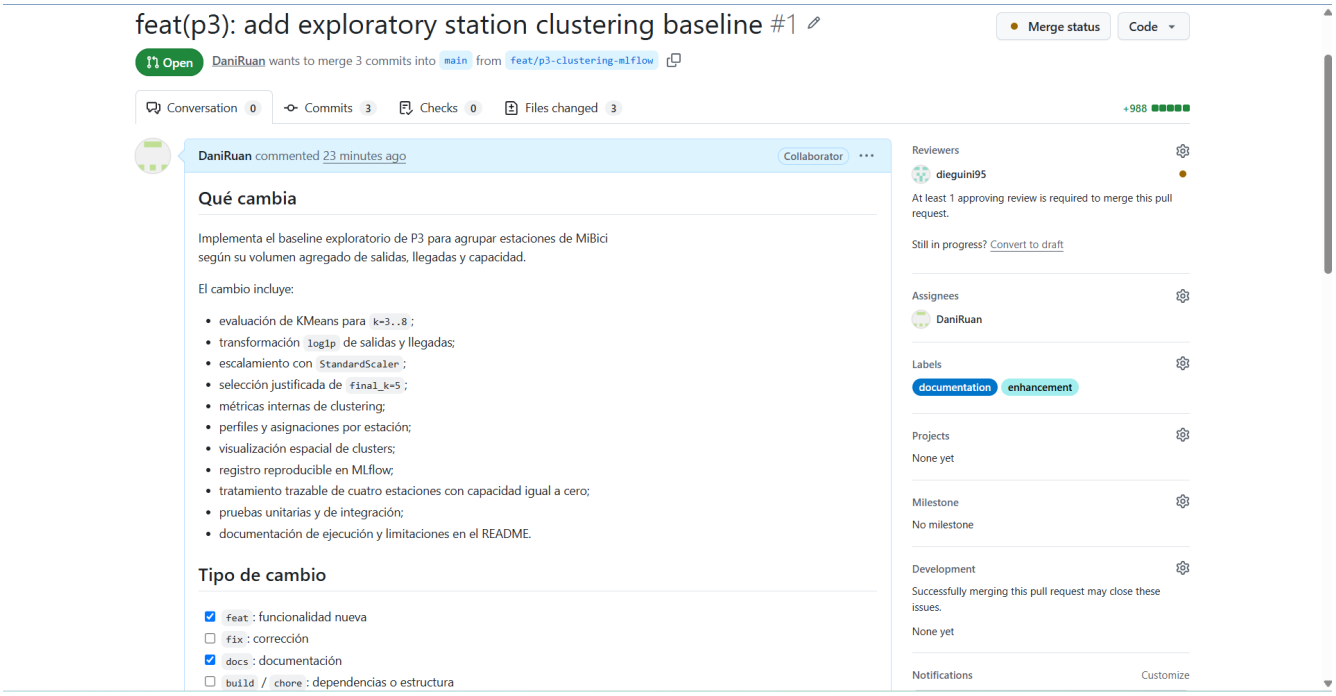


Figura 17. Pull request #1 en GitHub: feat(p3) baseline de clustering, de DaniRuan, revisada y aprobada por dieguini95.



Figura 18. Pull request #2 en GitHub: feat(p2) clasificación de riesgo, de dieguini95 (Diego Sánchez), revisada y aprobada por DaniRuan.



Figura 19. Pull request #3 en GitHub: feat(p1) pronóstico estación-hora, de Drezneck-RM (Saúl Salgado), revisada y aprobada por dieguini95.

8. Referencias

Briseño, R. A., López, J. C., Maciel Arellano, R., Larios, V. M., Beltrán, R. J., y Orizaga T., J. A. (2020). Reentrenamiento continuo de un algoritmo LSTM con un sistema multiagente que implementa el modelo BDI para la predicción de viajes en bicicleta. *Research in Computing Science*, *149*(11). https://www.rcs.cic.ipn.mx/2020_149_11/Reentrenamiento%20continuo%20de%20un%20algoritmo%20LSTM%20con%20un%20sistema%20multiagente.pdf

Dorard, L. (2018, 9 de marzo). *From data to AI with the Machine Learning Canvas (Part I)*. Own Machine Learning (Medium). https://medium.com/louis-dorard/from-data-to-ai-with-the-machine-learning-canvas-part-i-d171b867b047

Gracia-Rivera, D. M., y Villalón-Turrubiates, I. E. (2022). Land use identification of the metropolitan area of Guadalajara using bicycle data: An unsupervised classification approach. En *IEEE International Geoscience and Remote Sensing Symposium* (IGARSS). https://doi.org/10.1109/igarss46834.2022.9884943

Hosseinpanahi, D., Zadtootaghaj, P., Lin, J., y Mohammadian, A. (K.). (2026). Machine learning models for bike-sharing demand forecasting. *Future Transportation*, *6*(1), 26. https://www.mdpi.com/2673-7590/6/1/26

Huyen, C. (2022). *Designing machine learning systems: An iterative process for production-ready applications*. O'Reilly Media.

Liu, X., y Pelechrinis, K. (2021). Excess demand prediction for bike sharing systems. *PLOS ONE*, *16*(6), e0252894. https://journals.plos.org/plosone/article?id=10.1371%2Fjournal.pone.0252894

MiBici. (s.f.). *Datos abiertos* [Conjunto de datos]. Sistema de Bicicleta Pública del Área Metropolitana de Guadalajara. https://mibici.net/es/datos-abiertos/

MLflow. (s.f.). *MLflow Tracking* [Documentación]. MLflow. https://mlflow.org/docs/latest/ml/tracking/

Minimize Regret. (2022, 30 de agosto). Where is the seasonal naive benchmark? [Entrada de blog]. https://minimizeregret.com/post/2022/08/30/where-is-the-seasonal-naive-benchmark/

O'Mahony, E., y Shmoys, D. B. (2015). Data analysis and optimization for (Citi)Bike sharing. *Proceedings of the AAAI Conference on Artificial Intelligence*, *29*(1). https://doi.org/10.1609/aaai.v29i1.9245

Schimohr, K., Doebler, P., y Scheiner, J. (2023). Prediction of bike-sharing trip counts: Comparing parametric spatial regression models to a geographically weighted XGBoost algorithm. *Geographical Analysis, 55*(4), 651-684. https://doi.org/10.1111/gean.12354

scikit-learn developers. (s.f.). *Model evaluation: Quantifying the quality of predictions* [Documentación]. scikit-learn. https://scikit-learn.org/stable/modules/model_evaluation.html

scikit-learn developers. (s.f.). *Supervised learning* [Documentación]. scikit-learn. https://scikit-learn.org/stable/supervised_learning.html

scikit-learn developers. (s.f.). *Clustering* [Documentación]. scikit-learn. https://scikit-learn.org/stable/modules/clustering.html

Treveil, M., Omont, N., Stenac, C., Lefevre, K., Phan, D., Zentici, J., Lavoillotte, A., Miyazaki, M., y Heidmann, L. (2020). *Introducing MLOps: How to scale machine learning in the enterprise*. O'Reilly Media.

Wilson, B. (2022). *Machine learning engineering in action*. Manning Publications.